Universidad Nacional Abierta y a Distancia

Vicerrectoría Académica y de Investigación

Curso: Minería para Big Data,

Código: 203238426

Guía de aprendizaje – Tarea 3 - Modelado para grandes volúmenes de Datos

1. Datos de la Tarea

Tabla 1. Tabla de descripción

Aspecto	Descripción
1. Tipo de actividad	Independiente
2. Momento de la evaluación	**Intermedio**
3. Unidad gestora	Escuela de Ciencias Básicas Tecnología e Ingeniería ECBTI
4. Puntaje de la Tarea	**120 puntos**
5. La actividad inicia el:	miércoles, 18 de marzo de 2026
6. La actividad finaliza el:	jueves, 9 de abril de 2026
7. Horas de trabajo independiente del estudiante	23 horas

2. Descripción detallada de la actividad de aprendizaje

Con el desarrollo de esta actividad se espera que se alcance el siguiente resultado de aprendizaje:

Implementar técnicas de minería de datos para identificar patrones y correlaciones significativas mediante el análisis de conjuntos de datos complejos, utilizando herramientas como Python, RStudio y

Weka.

La actividad consiste en:

El estudiante ejecutará un proceso ETL completo que incluye la extracción, transformación y carga de datos, seguido de limpieza y corrección. Posteriormente, implementará técnicas de minería de texto y análisis de correlaciones para identificar patrones significativos, utilizará Weka para realizar clustering K-means, regresión lineal y logística para predicciones. Presentará un informe escrito que documente cada paso del proceso que incluya, los resultados obtenidos e interpretaciones.

Esta actividad desarrolla competencias en el procesamiento y análisis de grandes volúmenes de datos, fomentando la toma de decisiones basada en evidencia y preparando al estudiante para desafíos reales en el campo de la ciencia de datos.

Para el desarrollo de esta actividad se requieren los siguientes materiales y recursos:

- Lea detenidamente la guía de la actividad y la rúbrica de evaluación.
- El estudiante deberá contar con acceso a internet e ingresar al campus virtual donde encontrará la guía de aprendizaje.
- Realizar consultas disponibles en la biblioteca virtual y recursos sugeridos.
- Instalador Weka.
- Explorar Colab.

Para el desarrollo de esta actividad debe seguir los siguientes pasos:

Paso 1:

Actividad 1: Gestión y transformación de datos

El estudiante desarrollará un proceso ETL utilizando Google Colab como entorno de trabajo, donde deberá importar la base de datos (Anexo 1 - Dataset1.csv), realizando las siguientes tareas: identificar y documentar los tipos de datos de cada atributo, traducir los encabezados de las columnas del inglés al español para mejorar la comprensión de los datos, realizar la conversión del tipo de dato 'CustomerID' a formato string, y aplicar técnicas de limpieza para eliminar valores nulos que puedan afectar análisis posteriores.

Todo el proceso debe estar documentado en un notebook de Colab, incluyendo comentarios explicativos del código y justificación de las transformaciones realizadas.

Paso 2:

Actividad 2: Procesamiento de texto con RStudio o Python

El estudiante desarrollará un análisis de minería de texto utilizando el código proporcionado (Anexo 2 - Text Mining_Don_Quijote.R o Anexo 3 - Text Mining_Don_Quijote.ipynb, Anexo 4 - requirements.txt) para examinar la relación entre bigramas y descubrir patrones significativos en los datos textuales. A partir del código, el estudiante deberá identificar y documentar las diferentes técnicas de minería de texto empleadas, analizar las correlaciones existentes entre los bigramas generados, y formular al menos tres conclusiones en la frecuencia de aparición, la fuerza de las correlaciones

encontradas, su relevancia en el contexto del análisis y el análisis de sentimientos de los textos. El trabajo presentado se debe evidenciar los resultados y graficas que genera el código.

Paso 3:

Actividad 3: Análisis de Datos con Weka

El estudiante realizará un análisis de clustering utilizando el algoritmo SimpleKMeans en Weka, empleando el conjunto de datos proporcionado por el tutor. El proceso iniciará con la preparación de los datos, eliminando la variable "clase" para garantizar un aprendizaje no supervisado. Se requiere implementar el modelo con diferentes números de clusters (3, 4 y 8), deberá presentar un cuadro comparativo que muestre la relación entre el número de iteraciones y la suma de errores cuadrados de cada modelo, a partir de los diagramas de dispersión determinar cuál es la mejor configuración. En el documento se debe evidenciar los resultados arrojados por Weka de cada clúster y los diagramas de dispersión.

Paso 4:

Actividad 4: Predicciones con Weka

El estudiante realizará un análisis comparativo de los algoritmos de regresión lineal y logística, comenzando con una descripción de las características y ventajas. Posteriormente, aplicará estos algoritmos a dos conjuntos de datos que se encuentran en la carpeta data de Weka iris y cpu, donde deberá identificar y justificar qué modelo de regresión es más apropiado para cada conjunto de datos basándose en la descripción. Adicionalmente, el estudiante creará dos bases de datos propias con un mínimo de siete instancias cada una, diseñadas para realizar predicciones con ellas al atributo class. En el documento se debe evidenciar la tabla comparativa, los resultados de los modelos arrojados

por Weka y la conclusión de las predicciones.

Paso 5:

Actividad 5. Consolida la información.

Por último, el estudiante deberá consolidar todas las actividades desarrolladas en un informe en formato PDF que incluya: el proceso ETL documentado en el notebook de Colab con sus transformaciones y limpieza de datos, el análisis de minería de texto realizado en RStudio con sus resultados, gráficas y conclusiones sobre los bigramas y correlaciones encontradas, el análisis comparativo del clustering K-means realizado en Weka con sus diferentes configuraciones (3, 4 y 8 clusters), incluyendo los diagramas de dispersión y resultados de cada modelo, y finalmente el análisis comparativo de los algoritmos de regresión lineal y logística aplicados tanto a los conjuntos de datos de Weka como a las bases de datos propias creadas. El informe debe incluir las conclusiones de cada análisis realizado y del trabajo en general, estar correctamente referenciado siguiendo normas APA e incluir las capturas de pantalla relevantes que evidencien el trabajo realizado.

3. Indicaciones para el desarrollo y entrega de las evidencias de aprendizaje.

Las evidencias de aprendizaje son las acciones, productos o procesos observables que se realizan y/o entregan para manifestar las capacidades, habilidades, aptitudes y actitudes adquiridas, y que, a su vez, servirán al docente para verificar y evaluar su desempeño.

Las evidencias a desarrollar independientemente son:

- Presentar los avances en el foro colaborativo.
- Comentar el aporte de un compañero.
- Subir un archivo en formato PDF en el entorno de aprendizaje y

evaluación siguiendo el formato de ejemplo

«T3G2_Jorge_Quintero.pdf». Este archivo debe incluir las evidencias, una descripción detallada de cada línea de código y enlaces donde se requiera.

Tenga en cuenta que todos los productos escritos independientes o grupales deben cumplir con las normas de ortografía y con las condiciones de presentación que se hayan definido.

En cuanto al uso de referencias considere que el producto de esta actividad debe cumplir con las normas APA

En cualquier caso, cumpla con las normas de referenciación y evite el plagio académico, para ello puede apoyarse revisando sus productos escritos mediante la herramienta Turnitin que encuentra en el campus virtual.

4. Situaciones de orden académico

Considere que en el acuerdo 029 del 13 de diciembre de 2013, artículo 99, se considera como faltas que atentan contra el orden académico, entre otras, las siguientes: literal e) "El plagiar, es decir, presentar como de su propia autoría la totalidad o parte de una obra, trabajo, documento o invención realizado por otra persona. Implica también el uso de citas o referencias faltas, o proponer citad donde no haya coincidencia entre ella y la referencia" y liberal f) "El reproducir, o copiar con fines de lucro, materiales educativos o resultados de productos de investigación, que cuentan con derechos intelectuales reservados para la Universidad"

Las sanciones académicas a las que se enfrentará el estudiante son las siguientes:

a) En los casos de fraude académico demostrado en el trabajo académico o evaluación respectiva, la calificación que se impondrá será de cero puntos sin perjuicio de la sanción disciplinaria correspondiente.

b) En los casos relacionados con plagio demostrado en el trabajo académico cualquiera sea su naturaleza, la calificación que se impondrá será de cero puntos, sin perjuicio de la sanción disciplinaria.